가우시안 모델 학습

전력사용량 예측 프로젝트에서 **가우시안 프로세스 회귀(Gaussian Process Regression, GPR)** 모델을 맡아 학습 코드를 만들고, 건물유형별로 검증한 과정과 결과를 정리했다. 코드는 `Project/source_code_file/3_gaussian_model.py`, 결과는 `Project/model_output/gaussian/` 이다.

> **작업일** 2026-11-08 | **담당** 송이 (가우시안) | **팀 마감** 11/10 맡은 모델 학습 코드 완성
> **상태** 코드 완성. 10개 유형 100동 학습·검증·test 예측 완료, 제출 파일 `gaussian_submission.csv` (16,800행) 생성
> **검증 SMAPE** 100동 전체 15.49 (최고 IDC 3.20, 최저 백화점 23.70) | 오차 원인 3가지 확인, 고칠 방향 6절

0. 작업 흐름

순서	한 일	결과
1	팀 자료 확인 (PDF 0~3번, 카톡 역할 분담, 전처리된 데이터 구조)	입력 가능한 열, test에 없는 열(일조·일사) 파악
2	모델 설계: 건물 1동당 GPR 1개, 입력 10개, 로그 변환, ARD RBF 커널	1절
3	검증 방법 결정: 훈련 85일 중 마지막 7일을 시간순으로 떼어 평가	2절
4	`3_gaussian_model.py` 작성 (기존 코드와 같은 폴더 구조·스타일)	3절
5	아파트 9동으로 먼저 실행해 정상 작동 확인 (약 5분 30초)	SMAPE 10.75
6	10개 유형 전체 실행 (병렬 10개, 약 75분), 그동안 오차 큰 건물 분석	4·5절
7	팀 공유용 `README_gaussian.md` 작성	실행법·설계·개선안

1. 모델 설계

건물 1동 = 모델 1개

가우시안 프로세스는 데이터 수 n의 세제곱(n^3)에 비례해 느려지고 메모리는 n^2로 늘어난다. 유형 전체(약 2만 행)를 한 번에 넣으면 감당이 안 되므로 **건물마다 2,040행으로 따로 학습**한다. 건물 100동이면 모델 100개가 된다. 연면적·냉방면적·태양광·ESS·PCS 용량은 건물 안에서 상수라 입력에서 뺐다.

입력 변수 10개

구분	변수	설명
날씨	temperature, precipitation, wind_speed, humidity	test.csv에도 있는 기상 4개. 일조·일사는 test에 없어서 제외

구분	변수	설명
시간	hour_sin, hour_cos	시(0~23)를 주기 함수로 변환. 23시와 0시가 이어지도록
시간	weekday_sin, weekday_cos	요일(0~6)을 주기 함수로 변환. 일요일과 월요일이 이어지도록
시간	is_weekend	토·일이면 1
추세	day_index	6월 1일부터 지난 일수(소수). 여름철 사용량 변화 추세를 담기 위해

날짜는 `num_date_time`("11_20240601 00")에서 복원했다. 입력은 `StandardScaler`로 표준화한다.

출력과 커널

- **출력**: `power_consumption`에 log1p를 씌워 학습하고 예측 후 expm1로 되돌린다. 전력소비량은 치우친 양수이고 평가지표 SMAPE가 상대 오차라서 로그 변환이 유리하다. 음수 예측은 0으로 자른다.
- **커널**: `ConstantKernel × RBF(length_scale 10개, ARD) + WhiteKernel`. 입력마다 길이척도를 따로 두어(ARD) 중요하지 않은 입력은 길이척도가 커지며 자동으로 무시된다. 실제로 강수량은 거의 모든 건물에서 상한(1,000)에 닿아 영향이 없다고 나왔다. WhiteKernel은 관측 잡음을 흡수한다.
- **하이퍼파라미터**: 주변 가능도(marginal likelihood) 최대화, L-BFGS-B, 재시작 1회. `normalize_y=True`.

2. 검증 방법

시계열이므로 무작위 분할 대신 **시간순**으로 나눈다. 훈련 85일(6/1~8/24) 중 **마지막 7일(8/18~8/24)**을 검증용으로 뗐다. test 기간(8/25~8/31)과 같은 길이다.

단계	학습 데이터	예측 대상	목적
① 검증	앞 78일 (1,872행/동)	뒤 7일 (168행/동)	커널 최적화, SMAPE·MAE·RMSE 측정
② 재학습	85일 전체 (2,040행/동)	test 7일 (168행/동)	①에서 찾은 커널 값을 고정하고 다시 학습, 제출용 예측

평가지표는 대회와 같은 SMAPE다. 두 값의 차이를 두 값 평균으로 나눈 비율의 평균(%)이며 작을수록 좋다.

3. 실행 방법과 결과 파일

```
cd source_code_file
python 3_gaussian_model.py apartment          # 건물유형 하나
python 3_gaussian_model.py apartment hotel    # 여러 개
python 3_gaussian_model.py all                # 10개 전부 + 제출 파일 합치기
```

파일 (model_output/gaussian/)	내용
`{유형}_validation.csv`	건물별 SMAPE, MAE, RMSE, 학습 시간, 학습된 커널 식

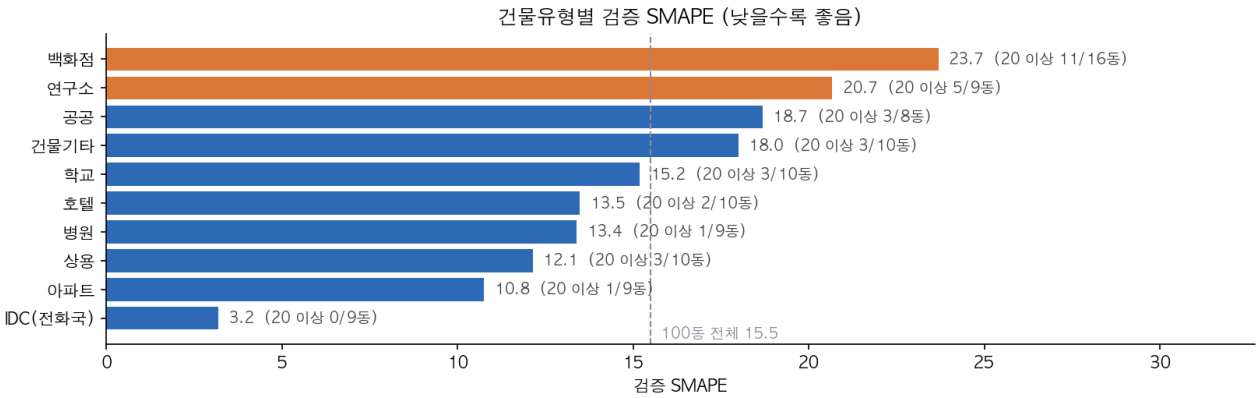
파일 (model_output/gaussian/)	내용
`{유형}_validation_pred.csv`	검증 기간 실제값과 예측값 (시간 단위)
`{유형}_prediction.csv`	test 기간 예측. 열은 num_date_time, answer
`gaussian_submission.csv`	`all` 실행 시 10개 유형 예측을 합친 제출 파일 (16,800행)

CPU 코어 수만큼 건물을 병렬로 학습한다. 이 맥북(10코어)에서 건물 1동은 2~9분, 100동 전체는 약 75분 걸렸다(CPU 시간 합계 약 10시간).

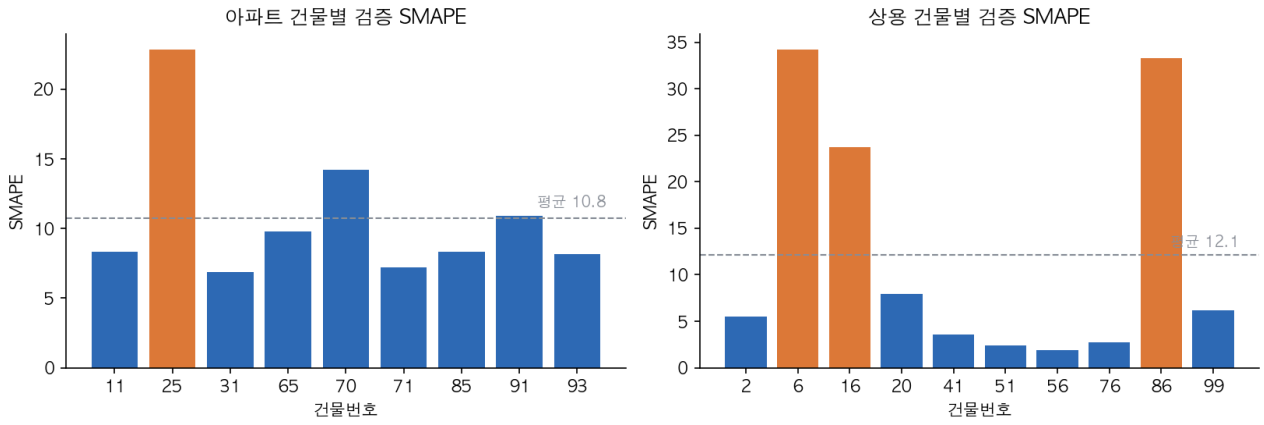
4. 결과

건물유형별 검증 결과 (10개 유형, 100동 완료)

건물유형	건물 수	검증 SMAPE	건물별 범위	SMAPE 20 이상
아파트	9동	10.75	6.9 ~ 22.9	1동
상용	10동	12.14	1.9 ~ 34.2	3동
백화점	16동	23.70	4.2 ~ 45.1	11동
병원	9동	13.40	8.4 ~ 22.3	1동
호텔	10동	13.49	5.8 ~ 26.9	2동
IDC(전화국)	9동	3.20	0.9 ~ 9.3	0동
건물기타	10동	18.00	5.5 ~ 54.9	3동
공공	8동	18.68	8.9 ~ 30.4	3동
연구소	9동	20.67	8.4 ~ 31.4	5동
학교	10동	15.19	6.1 ~ 22.1	3동
전체	**100동**	**15.49**		**32동**



유형별 검증 SMAPE. 주황색은 20 이상. IDC(전화국)는 하루 종일 일정하게 쓰는 건물이라 가장 잘 맞고, 백화점·연구소는 휴무일과 추세 변수 문제로 가장 나쁘다.



건물별 검증 SMAPE. 주황색은 20 이상. 점선은 유형 평균.

아파트 (9동) — 전체 SMAPE 10.75

건물번호	SMAPE	MAE(kWh)	RMSE(kWh)	학습 시간
11	8.33	126.1	159.2	411초
25	22.86	361.5	495.9	452초
31	6.87	69.3	82.7	401초
65	9.80	3.8	6.0	348초
70	14.21	438.1	556.2	352초
71	7.22	97.6	130.8	325초
85	8.36	2.2	3.3	338초
91	10.93	226.8	311.3	391초
93	8.18	147.3	183.9	365초

상용 (10동) — 전체 SMAPE 12.14

건물번호	SMAPE	MAE(kWh)	RMSE(kWh)	학습 시간
2	5.49	90.0	118.6	284초
6	34.22	1,203.6	1,512.2	279초
16	23.72	273.2	408.9	274초
20	7.91	159.6	248.3	288초
41	3.59	99.5	138.9	264초
51	2.44	82.4	100.9	289초
56	1.89	108.2	141.1	253초
76	2.71	92.2	129.1	328초
86	33.28	608.0	947.6	283초

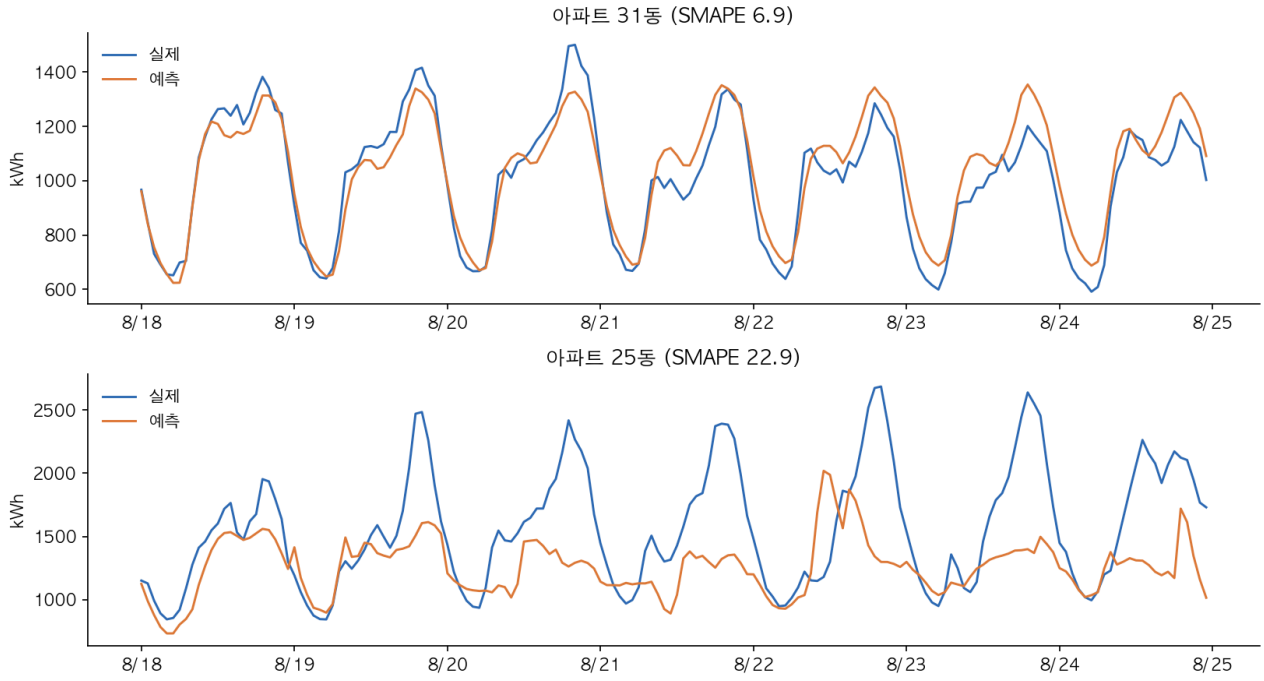
건물번호	SMAPE	MAE(kWh)	RMSE(kWh)	학습 시간
99	6.16	66.8	88.8	293초

백화점 (16동) — 전체 SMAPE 23.70

건물번호	SMAPE	MAE(kWh)	RMSE(kWh)	학습 시간
18	9.64	145.4	210.5	244초
19	38.77	538.1	686.1	331초
27	25.27	304.3	353.2	418초
29	45.06	456.2	499.6	274초
32	26.53	366.5	467.7	314초
34	4.20	457.1	614.5	368초
40	22.77	262.4	328.1	326초
45	30.33	1,571.5	2,093.7	306초
54	28.71	778.2	985.1	281초
59	27.79	296.0	339.2	523초
63	31.04	417.3	480.0	264초
73	6.46	115.8	159.0	211초
74	23.23	700.5	873.8	221초
79	33.44	1,952.8	2,437.9	218초
88	7.63	158.8	243.4	182초
95	18.27	419.8	612.3	176초

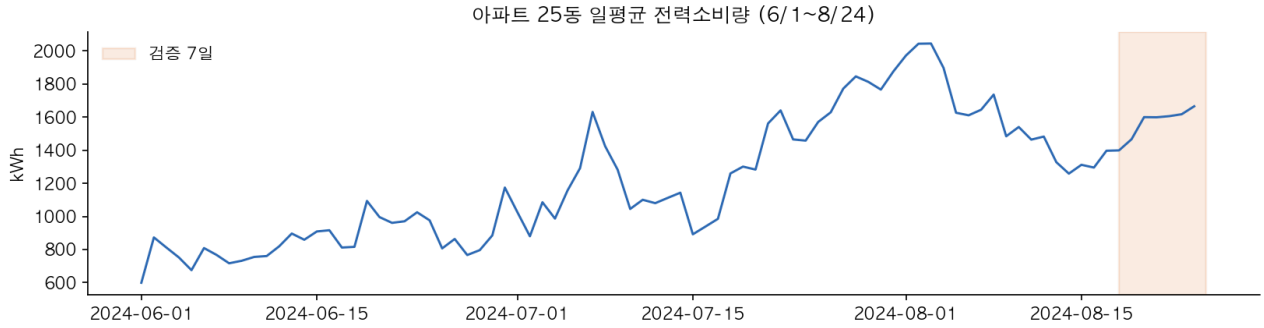
5. 오차 분석

대부분 건물은 SMAPE 2~11로 하루 패턴을 잘 따라간다. 오차가 큰 건물(20 이상)은 세 가지 원인으로 나뉜다. 세 번째 원인(추세 변수의 평균 회귀)은 거의 모든 건물에 조금씩 영향을 주고 있어 가장 먼저 고쳐야 한다.



검증 7일 실제(파랑) vs 예측(주황). 위: 잘 맞는 아파트 31동. 아래: 수준을 낮게 잡은 아파트 25동.

원인 1. 여름 내내 올라간 추세를 못 따라감 — 아파트 25동



아파트 25동 일평균 전력소비량. 6월 초 약 755kWh에서 8월 말 약 1,666kWh로 두 배 넘게 늘었다.

RBF 커널은 학습 데이터 범위를 벗어나면 평균으로 되돌아가는 성질이 있어, 상승 추세의 끝에서 검증 7일을 약 20% 낮게 예측했다. 낮 시간 피크를 특히 못 잡는다. 아파트 70동(SMAPE 14.2)은 일평균은 맞지만 기온 길이척도가 작아(0.62) 날씨에 과민하게 반응해 날마다 ±15% 출렁인다.

원인 2. 공휴일을 평일로 학습 — 상용 6·16·86동

상용 건물은 평일 사용량이 주말의 약 2배다. 그런데 8/15(광복절, 목요일) 사용량이 주말 수준으로 떨어진 것이 훈련 데이터에 들어 있다. 모델에는 공휴일 변수가 없어 "목요일은 가끔 낮다"로 배웠고, 검증 기간 평일을 전반적으로 낮게, 특히 **8/22(목)**을 크게 낮게 예측했다.

상용 86동 일평균	8/19(월)	8/20(화)	8/21(수)	8/22(목)	8/23(금)	8/24(토)
실제 (kWh)	1,937	1,921	1,996	1,928	1,862	1,096
예측 (kWh)	1,234	1,355	1,368	**616**	1,136	1,008

6동, 16동도 같은 모양이다. 이 원인은 명확하고 고치기 쉽다. 공휴일 변수(`is_holiday` : 6/6 현충일, 8/15 광복절)를 넣고 주말과 합쳐 "쉬는 날" 변수로 쓰면 된다. test 기간(8/25~8/31)에는 공휴일이 없다.

원인 3. 추세 변수(day_index)가 학습 범위 밖에서 평균으로 되돌아감 — 백화점 전반

백화점은 사용량이 하루하루 거의 일정한데도 SMAPE가 23.7로 가장 나빴다. 검증 주를 날짜별로 보면 실제는 평평한데 **예측이 매일 조금씩 내려간다**. 추세용으로 넣은 day_index의 RBF 길이척도가 짧게(약 8~10일) 학습되어, 훈련 마지막 날을 지나면 예측이 전체 기간 평균 쪽으로 미끄러지기 때문이다. 여름 후반 사용량이 평균보다 높은 건물은 모두 낮게 예측된다. test 기간도 훈련 끝 바로 뒤 7일이라 같은 문제가 그대로 생긴다.

백화점 79동 일평균	8/18(일)	8/19(월)	8/20(화)	8/21(수)	8/22(목)	8/23(금)	8/24(토)
실제 (kWh)	6,745	**3,199**	6,873	6,622	6,488	6,453	6,625
예측 (kWh)	6,372	5,608	5,494	5,395	5,367	5,101	5,250

고치는 방법은 둘 중 하나다. ① day_index를 빼고 날씨·시간만으로 학습(가장 단순), ② day_index에 선형 커널(DotProduct)을 더하거나 길이척도 하한을 30일 이상으로 두어 완만한 추세만 담기. 아파트 25동 같은 상승 추세 건물은 ②가 유리하다.

또 하나, 8/19(월) 79동·19동, 8/10(토) 29동처럼 **월 1회 정기 휴무일**에 사용량이 절반으로 떨어진다. 휴무 날짜는 건물마다 달라 날씨·요일로는 예측할 수 없다. test 기간에 휴무일이 들어 있으면 그날은 어떤 모델이든 틀리므로, 팀 전체가 같은 조건으로 비교하면 된다.

6. 다음 할 일

순위	할 일	기대 효과
1	(완료) 전체 10개 유형 실행, `gaussian_submission.csv` 생성. test 16,800행과 키 일치, 결측·음수 없음 확인	11/10 마감 산출물
2	day_index 처리 변경: 제거하거나 선형 커널(`DotProduct`) 추가 / 길이척도 하한 30일. 두 방식을 아파트·백화점으로 비교	백화점처럼 평평한 건물의 평균 회귀 제거, 아파트 25동 같은 상승 추세 반영. 전 건물에 영향
3	공휴일 변수 추가 (`is_holiday` : 6/6, 8/15. 또는 주말과 합친 `is_off_day`)	상용·학교·공공 등 평일/휴일 차이 큰 유형의 큰 오차 제거
4	RBF 대신 Matern 커널 비교, 시간 입력에 주기 커널(ExpSineSquared) 시도	하루 패턴 표현력
5	결정트리·베이지안 팀원 결과와 같은 검증 기준(마지막 7일 SMAPE)으로 비교표 만들기	발표 자료
6	깃 레포지토리에 코드·README 커밋	팀 공유

참고: 기존 분석 코드의 그래프 폰트가 Malgun Gothic(윈도우)으로 되어 있어 맥에서는 한글이 깨진다. 맥에서는 AppleGothic으로 바꾸면 된다.