가우시안 모델 개선

『4_가우시안 모델 학습』에서 찾은 오차 원인 두 가지(공휴일 미반영, 추세 변수의 평균 회귀)를 고친 v2 모델의 변경 내용과 결과다. 코드는 같은 파일 `Project/source_code_file/3_gaussian_model.py` 이고, v1 결과는 `model_output/gaussian_v1/` , v2 결과는 `model_output/gaussian/` 에 있다.

> **작업일** 2026-11-09 | **담당** 송이 (가우시안)
> **상태** v2 100동 완료. 검증 SMAPE 100동 전체 **15.49 → 8.71**, SMAPE 20 이상 건물 32동 → 3동. 제출 파일 재생성.

1. 무엇을 고쳤나

변경 1. 공휴일 변수

훈련 기간에 공휴일이 이틀 있다. **6/6 현충일과 8/15 광복절, 둘 다 목요일**이다. v1은 공휴일 변수가 없어서 이 이틀의 낮은 사용량을 "목요일은 가끔 낮다"로 배웠고, 상용 건물의 검증 8/22(목)을 절반 수준으로 예측했다. v2는 공휴일을 주말과 합친 `is_off_day` (쉬는 날이면 1) 하나로 쓴다. test 기간(8/25~8/31)에는 공휴일이 없다.

변경 2. 추세 변수(day_index) 처리

v1은 6/1부터 지난 일수 day_index를 RBF 커널에 그대로 넣었다. 길이척도가 8~10일로 짧게 학습되어 훈련 마지막 날을 지나면 예측이 전체 평균 쪽으로 매일 미끄러졌다(백화점에서 두드러짐). 세 가지 대안을 만들어 `--trend` 옵션으로 고를 수 있게 했다.

방식	내용	기대
`none`	day_index를 뺀다. 날씨·시간·쉬는 날만으로 학습	평균 회귀 없음. 대신 여름철 수준 변화는 기온이 대신 설명해야 함
`smooth`	day_index를 쓰되 RBF 길이척도 하한을 30일로 고정	완만한 계절 추세만 담고, 짧은 변동에는 반응 못 하게
`linear`	log(전력)을 day_index에 대한 직선으로 먼저 맞추고, 잔차를 GP로 학습. 예측 때 직선을 다시 더함	아파트 25동처럼 꾸준히 오르는 건물의 추세를 7일 뒤까지 연장
`v1`	기존 설정 (비교용)	

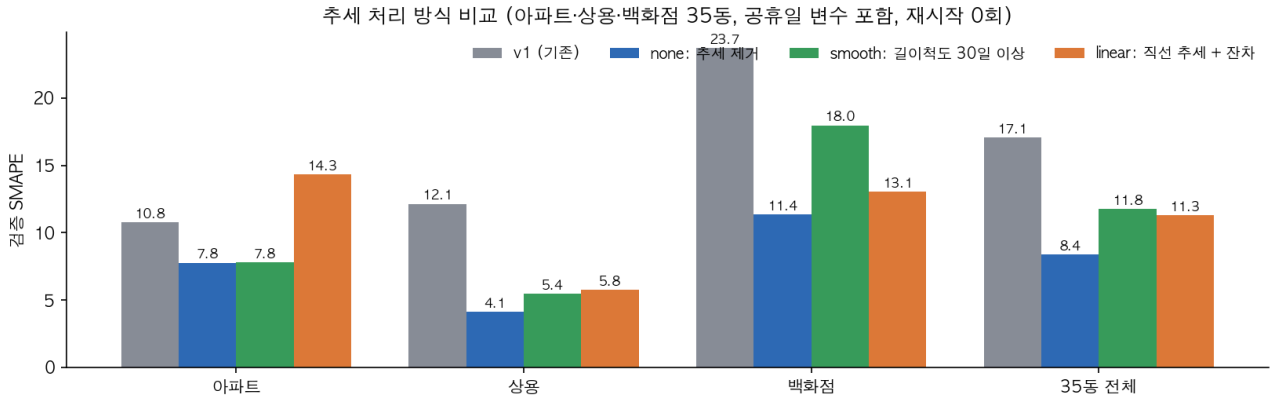
```
python 3_gaussian_model.py apartment commercial department_store --trend none --restarts 0 --validate-only --tag cmp_none
python 3_gaussian_model.py all --trend none      # 최종
```

그 밖의 설계(건물 1동당 모델 1개, 날씨 4개 + 시·요일 sin/cos, log1p 출력, ConstantKernel × ARD RBF + WhiteKernel, 마지막 7일 검증 후 전체 재학습)는 v1과 같다.

2. 추세 방식 비교 (35동)

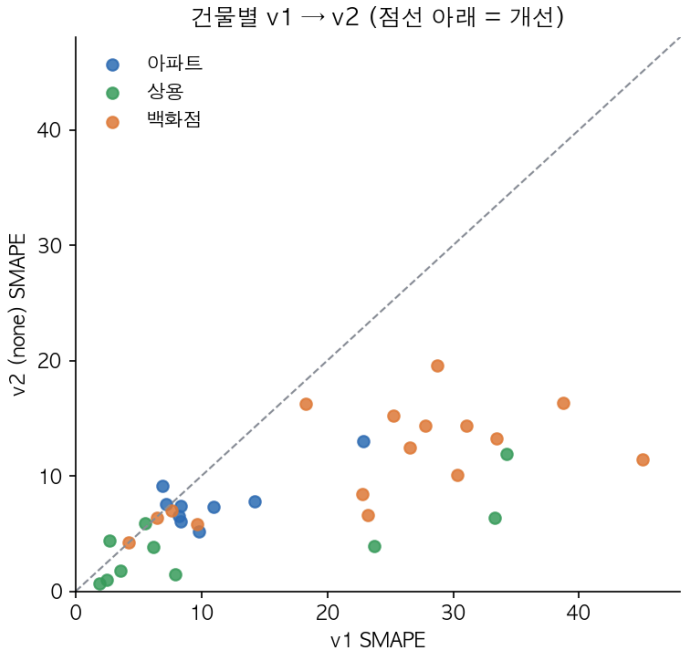
오차가 컸던 아파트·상용·백화점 35동으로 세 방식을 비교했다. 공휴일 변수는 모두 넣었고, 시간을 줄이려 커널 최적화 재시작을 0회로 했다. v1 수치는 이전 실행 값(재시작 1회)이다.

방식	아파트 (9동)	상용 (10동)	백화점 (16동)	35동 전체	SMAPE 20 이상
v1 (기존)	10.75	12.14	23.70	**17.07**	15동
none: 추세 제거	7.78	4.14	11.36	**8.38**	0동
smooth: 길이척도 30일 이상	7.83	5.45	17.97	**11.78**	5동
linear: 직선 추세 + 잔차	14.34	5.78	13.05	**11.31**	3동



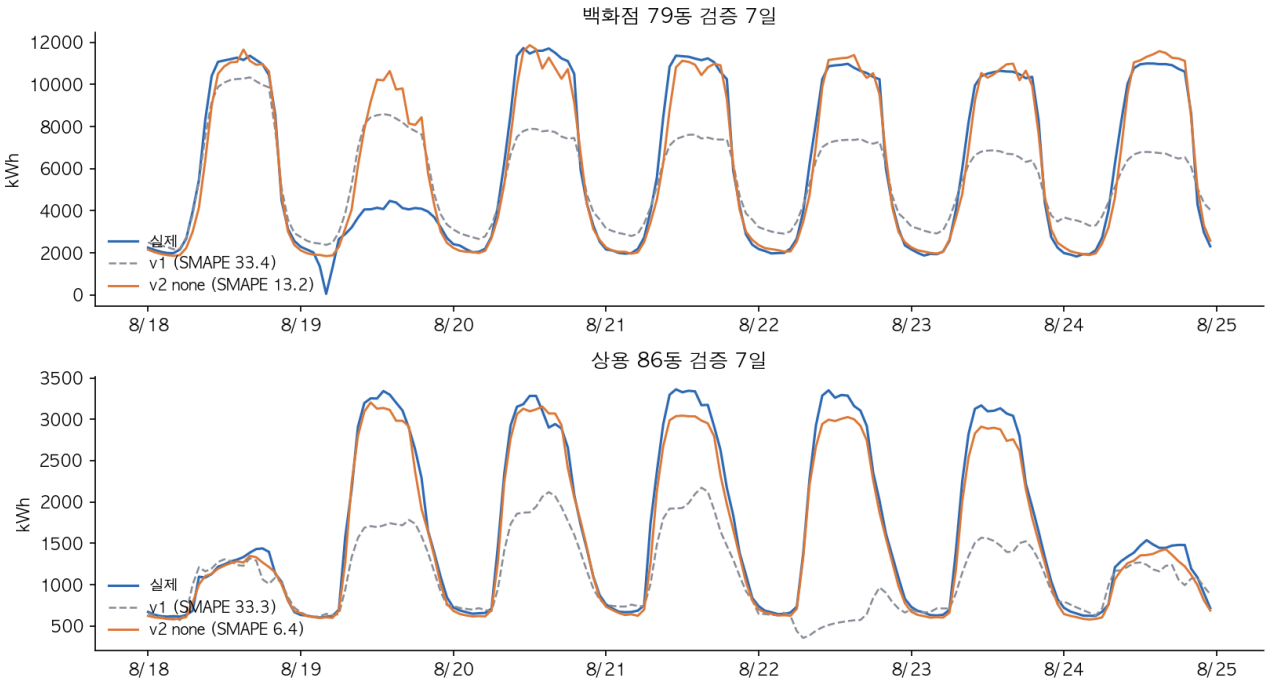
방식별 검증 SMAPE. 낮을수록 좋다.

none: 추세 제거가 35동 전체 SMAPE 8.38로 가장 좋아 최종 모델로 골랐다. 건물별로 보면 35동 중 30동이 v1보다 좋아졌다.



건물별 v1 대 v2 SMAPE. 점선 아래에 있으면 개선.

3. 고쳐진 사례



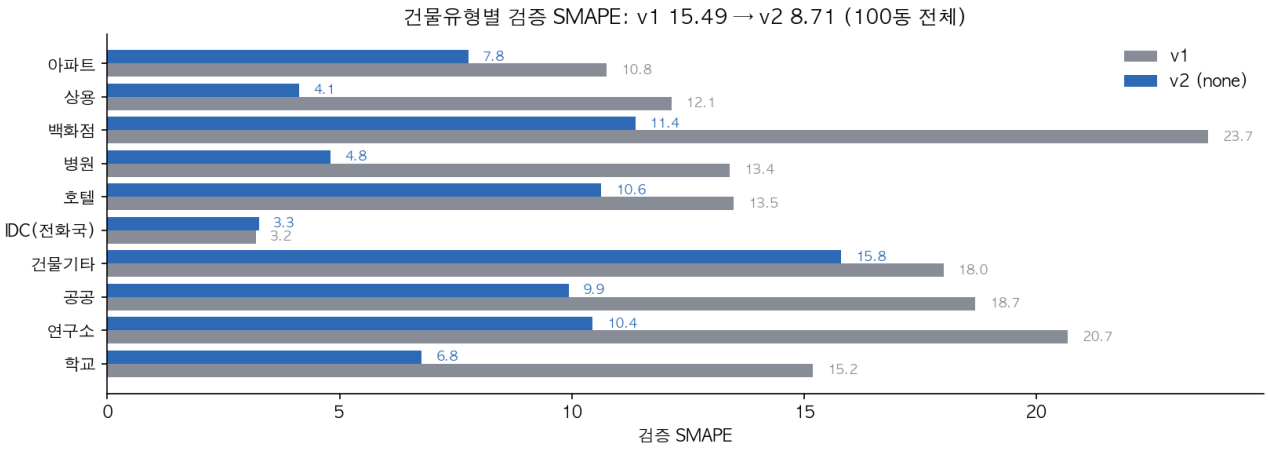
검증 7일 실제(파랑), v1 예측(회색 점선), v2 예측(주황). 위: 백화점 79동, 아래: 상용 86동.

- **백화점 79동**: v1은 예측이 매일 내려갔지만 v2는 수준을 유지한다. 8/19(월) 정기 휴무일은 두 버전 다 못 맞춘다. 휴무 날짜는 건물마다 달라 날씨·요일로는 알 수 없다.
- **상용 86동**: v1이 8/22(목)을 절반으로 예측하던 문제가 사라졌다. 공휴일 변수의 효과다.

4. 최종 결과 (10개 유형 100동, v2 none)

비교에서 가장 좋았던 **none** 방식과 공휴일 변수를 적용해 100동 전체를 다시 학습했다(재시작 1회). 검증 기준은 v1과 같다.

건물유형	건물 수	v1 SMAPE	v2 SMAPE	변화	SMAPE 20 이상 건물
아파트	9동	10.75	**7.78**	-2.97	1 → 0
상용	10동	12.14	**4.14**	-8.00	3 → 0
백화점	16동	23.70	**11.36**	-12.33	11 → 0
병원	9동	13.40	**4.81**	-8.59	1 → 0
호텔	10동	13.49	**10.62**	-2.86	2 → 1
IDC(전화국)	9동	3.20	**3.26**	+0.07	0 → 0
건물기타	10동	18.00	**15.79**	-2.21	3 → 1
공공	8동	18.68	**9.93**	-8.75	3 → 0
연구소	9동	20.67	**10.44**	-10.23	5 → 1
학교	10동	15.19	**6.77**	-8.42	3 → 0
전체	**100동**	**15.49**	**8.71**	**-6.78**	**32 → 3**



유형별 검증 SMAPE, v1(회색) 대 v2(파랑). 낮을수록 좋다.

제출 파일 `model_output/gaussian/gaussian_submission.csv` : 16,800행, 결측 0, 음수 0, test.csv와 키 일치 확인. 100동 중 84동이 v1보다 좋아졌다. 실행은 11/9 밤 11시 50분에 시작해 11/10 아침 8시 35분에 끝났다(맥북이 밤새 저전력 상태였을 수 있어 v1의 75분과 단순 비교는 어렵다).

v2에서도 남은 큰 오차 3동

건물	SMAPE	무슨 일이 있었나	모델로 잡을 수 있나
건물기타 7동	80.4	8/6부터 일평균 사용량이 약 1,300kWh에서 5,500kWh로 4배 뛰었다(가동 시작으로 보임). 새 수준의 데이터가 12일뿐이라 모델이 옛 수준과 새 수준 사이(2,000~2,700)를 예측한다.	추세 변수가 있었다면 잡았겠지만 그 변수가 다른 99동을 망쳤다. "최근 N일에 가중치" 같은 별도 처리가 필요
호텔 10동	27.4	검증 주에 실제 사용량이 11,000kWh에서 5,400kWh로 계속 떨어졌다(성수기 종료 또는 일부 시설 중단). 훈련 기간에는 없던 변화.	어렵다. 날씨·요일로 설명되지 않는 변화
연구소 94동	27.8	8/15(목)~8/16(금) 연휴·징검다리 휴일에 평일 사용량이 주말 수준이었다. 그 영향으로 평일 수준을 약 25% 낮게 잡는다.	8/16 같은 "사실상 휴일"을 쉬는 날에 포함하면 일부 개선

5. 남은 과제

순위	할 일	기대 효과
1	정기 휴무일(백화점 월 1회 등)은 모델로 예측 불가. 팀 전체가 같은 조건으로 비교하고, 발표 때 한계로 명시	평가 해석
2	재시작 횟수 2~3회로 늘려 커널 최적화 안정화 (시간 2~3배)	건물별 편차 감소
3	Matern 커널, 시간 입력에 주기 커널(ExpSineSquared) 비교	하루 패턴 표현력

순위	할 일	기대 효과
4	결정트리·베이지안 팀원 결과와 같은 검증 기준(마지막 7일 SMAPE)으로 비교표 작성	발표 자료
5	깃 레포지토리에 코드·README·보고서 커밋	팀 공유