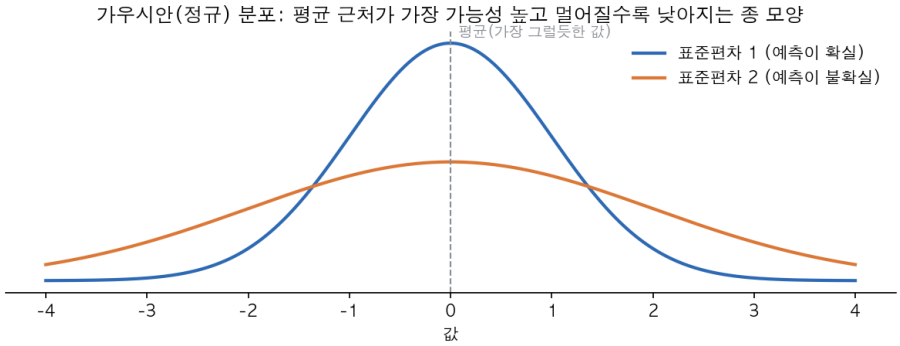
가우시안 모델 쉽게 설명

전력사용량 예측 프로젝트에서 맡은 **가우시안 프로세스 회귀**(Gaussian Process Regression, 줄여서 GPR 또는 GP)가 무엇인지, 우리 코드가 정확히 무슨 일을 하는지, 결과를 어떻게 읽는지를 처음 보는 사람 기준으로 정리했다. 수식은 쓰지 않았다. 자세한 수치와 실험 과정은 『4_가우시안 모델 학습』과 『5_가우시안 모델 개선』에 있다.

> **한 줄 요약**
> 가우시안 프로세스 회귀는 "**비슷한 상황에서는 비슷한 결과가 나온다**"는 규칙 하나로, 데이터 점들을 지나는 가장 그럴듯한 **매끄러운 곡선**을 찾아 예측하는 방법이다. 우리는 건물 100동마다 이 곡선을 하나씩 만들어, 날씨와 시간을 넣으면 그 시각의 전력소비량이 나오게 했다.

1. "가우시안"이 뭔데?

가우시안은 수학자 가우스의 이름을 딴 **정규분포**의 다른 이름이다. 종 모양 곡선 그거다. 사람 키, 시험 점수처럼 "평균 근처가 제일 많고 멀어질수록 드물다"는 모양을 말한다.

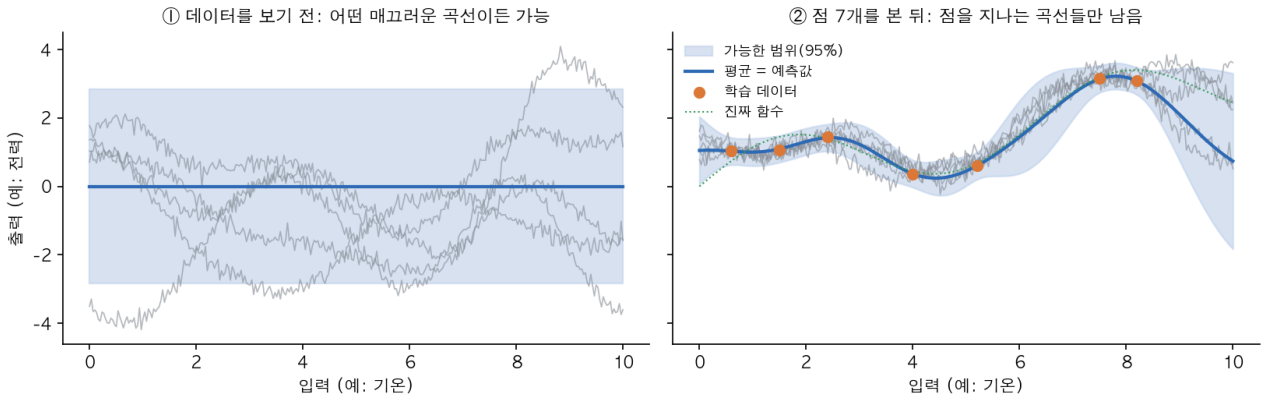


가우시안 분포. 가운데가 평균(가장 그럴듯한 값), 폭이 표준편차(얼마나 불확실한지).

예측에 쓰면 이렇게 읽는다. "내일 3시 전력소비량은 **평균 1,200kWh 근처**일 것 같고, **±100 정도**는 흔들릴 수 있다." 평균이 예측값, 폭이 자신감이다. 가우시안 모델은 답을 숫자 하나가 아니라 이런 **종 모양 하나**로 내놓는다.

2. "가우시안 프로세스"는 뭐가 다른데?

위에서는 한 시각의 값 하나에 종 모양이 하나였다. 가우시안 프로세스는 이걸 **모든 입력값에 대해 동시에** 한다. 그러면 종 모양이 쭉 이어져 "곡선 전체에 대한 확률"이 된다. 쉽게 말해 **가능한 곡선을 수없이 상상해 두고, 데이터에 맞는 곡선만 남기는 것**이다.



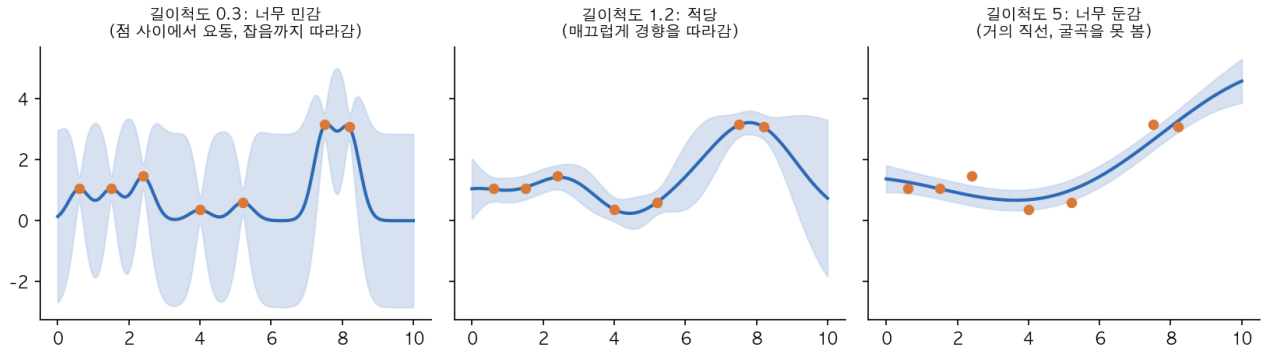
왼쪽: 데이터를 보기 전에는 어떤 곡선이든 가능하다(회색 선 = 후보 곡선들). 오른쪽: 점 7개를 보고 나면 그 점들을 지나는 곡선만 남고, 그 평균(파란 선)이 예측값, 파란 띠가 "이 범위 안일 것"이라는 자신감이다. 데이터가 없는 구간(오른쪽 끝)은 띠가 넓어진다.

> 회귀(regression)는 그냥 "숫자를 예측한다"는 뜻이다. 분류는 "아파트냐 호텔이냐"처럼 종류를 맞추는 것, 회귀는 "1,234kWh"처럼 숫자를 맞추는 것.

3. 핵심 부품: 커널 = "비슷함의 규칙"

곡선을 상상할 때 "얼마나 매끄러운 곡선만 허용할지"를 정하는 규칙이 **커널**이다. 우리가 쓴 커널은 세 조각으로 되어 있다.

조각	쉬운 뜻	우리 모델에서
RBF (가장 기본 커널)	"입력이 가까우면 출력도 비슷하다." 기온 25도와 26도의 전력은 비슷하고, 25도와 35도는 다를 수 있다.	날씨 4개 + 시간 5개, 입력 9개 전부에 적용
길이척도 (RBF 안의 숫자)	"얼마나 멀어져야 다른 상황으로 볼지." 작으면 민감, 크면 둔감.	입력마다 따로 학습(ARD). 길이척도가 1,000까지 커진 입력(예: 강수량)은 "영향 없음"이란 뜻
ConstantKernel	곡선이 위아래로 얼마나 크게 움직일 수 있는지	자동 학습
WhiteKernel	"측정값에는 잡음이 섞여 있으니 점을 정확히 통과하려 애쓰지 마라"	자동 학습. 과하게 맞추는 것(과적합)을 막음



같은 데이터, 다른 길이척도. 너무 작으면 잡음까지 따라가고, 너무 크면 굴곡을 못 본다. 우리 모델은 이 값을 데이터에서 자동으로 찾는다(주변 가능도 최대화라는 방법인데, "이 데이터가 나올 확률이 가장 높아지는 설정을 고른다"는 뜻이다).

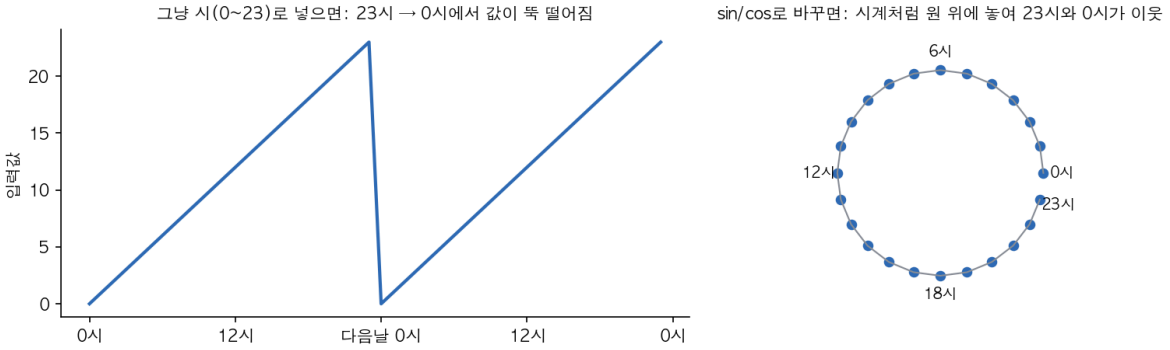
4. 장점과 단점, 그래서 어떻게 썼나

장점	단점
데이터가 적어도(수백~수천 개) 잘 맞는다	**느리다.** 데이터 수가 2배면 시간은 8배(세제곱). 2,000개는 수 분, 20,000개는 사실상 불가
예측값과 함께 **자신감(불확실성)**을 준다	데이터 범위 밖으로 나가면 평균으로 되돌아가는 성질이 있다 (v1에서 문제가 됐던 부분)
커널 설정값을 데이터에서 자동으로 찾는다. 사람이 튜닝할 게 적다	입력이 많아지면(수십 개 이상) 어려워진다

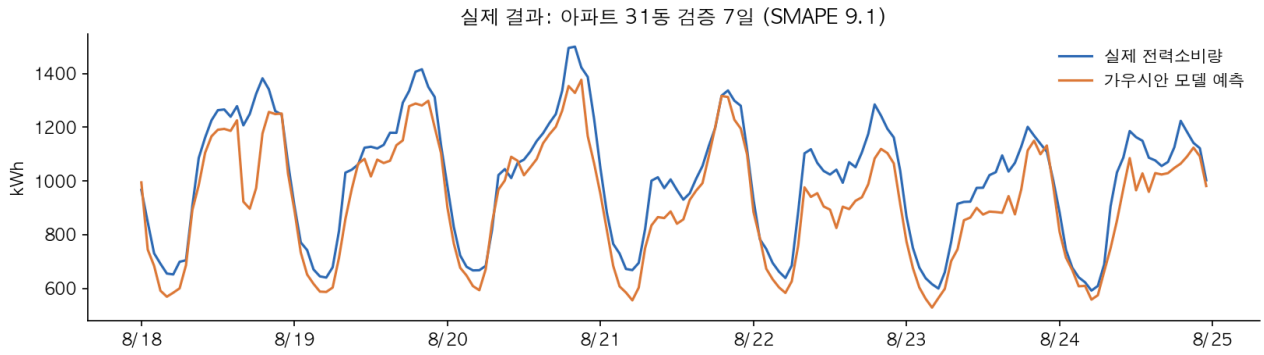
그래서 우리는 **건물 1동 = 모델 1개**로 했다. 건물 하나는 2,040행(85일 × 24시간)이라 가우시안이 감당할 크기이고, 건물 안에서는 면적·설비 용량이 똑같으니 입력도 날씨와 시간만 남아 단순해진다. 건물 100동이면 작은 모델 100개가 된다.

5. 우리 코드가 하는 일, 순서대로

1. **데이터 읽기**: 건물유형별 CSV(아파트, 호텔 …)를 읽는다. 팀에서 전처리해 둔 파일이다.
2. **입력 만들기**: 건물마다 시간마다 변하는 값만 쓴다.
   - 날씨 4개: 기온, 강수량, 풍속, 습도 (test.csv에도 있는 것만. 일조·일사는 test에 없어서 못 씀)
   - 시간 4개: 시와 요일을 각각 sin, cos 두 개로 변환 (아래 그림)
   - 쉬는 날 1개: 토·일 또는 공휴일(6/6, 8/15)이면 1
3. **출력 변환**: 전력소비량에 로그를 씌운다. 큰 값과 작은 값의 차이를 줄여서 모델이 "몇 % 차이"를 보게 하기 위해서다. 예측 후 다시 되돌린다.
4. **검증**: 85일 중 앞 78일로 학습하고 뒤 7일(8/18~8/24)을 예측해 실제와 비교한다. 이때 커널 설정값이 정해진다.
5. **재학습**: 그 설정값을 고정한 채 85일 전체로 다시 학습한다.
6. **test 예측**: 8/25~8/31 날씨·시간을 넣어 전력을 예측하고, 100동을 합쳐 제출 파일(16,800행)을 만든다.



시간을 sin/cos로 바꾸는 이유. 23시와 0시는 실제로 1시간 차이인데 숫자로는 23 차이가 난다. 원 위에 놓으면 이웃이 된다. 요일도 같은 방법으로 일요일과 월요일을 이어 준다.



실제 결과. 아파트 31동의 검증 7일. 모델은 날씨와 시간만 보고 하루 패턴(새벽 낮음, 저녁 피크)과 주말 차이를 잡아냈다.

6. 결과는 어떻게 읽나: SMAPE

대회 평가 지표 SMAPE는 "**실제와 예측이 몇 % 다른가**"를 모든 시각에 대해 평균 낸 값이다. 0이면 완벽, 작을수록 좋다. 실제 1,000에 예측 900이면 약 10.5, 예측 500이면 약 66.7이다. 큰 건물과 작은 건물을 같은 잣대로 볼 수 있어 kWh 차이(MAE)보다 공평하다.

SMAPE	느낌
5 이하	거의 정확. 하루 패턴과 수준을 다 맞춤 (IDC, 상용, 병원)
5 ~ 12	패턴은 맞고 피크 높이나 수준이 조금 어긋남 (아파트, 공공, 연구소, 호텔, 백화점)
12 ~ 20	몇몇 건물이 크게 틀려 평균을 끌어올림 (건물기타)
20 이상	그 건물에 모델이 모르는 일이 있었음 (갑자기 가동 시작, 휴무일 등)

우리 최종 결과는 **100동 전체 SMAPE 8.71**이다. 처음 버전(v1)은 15.49였다.

7. 처음 버전에서 무엇을 왜 고쳤나

문제	왜 생겼나	어떻게 고쳤나
상용 건물이 목요일을 절반으로 예측	훈련 기간 공휴일 둘(6/6 현충일, 8/15 광복절)이 하필 둘 다 목요일. 공휴일 변수가 없어서 "목요일은 가끔 낮다"로 배움	공휴일을 주말과 합친 "쉬는 날" 변수 추가
백화점 예측이 날마다 조금씩 내려감	"6/1부터 며칠째인지" 변수를 넣었더니, 훈련 마지막 날 이후는 모델이 본 적 없는 입력이라 평균으로 되돌아감 (4절의 단점)	그 변수를 뺌. 세 가지 대안 중 가장 좋았음

이 두 가지로 SMAPE 20 이상인 건물이 32동에서 3동으로 줄었다. 남은 3동은 검증 주에 사용량이 갑자기 4배가 되거나 절반이 된 건물이라 날씨·시간으로는 알 수 없는 경우다.

8. 발표나 질문에 대비한 짧은 답

Q. 왜 가우시안 프로세스를 골랐나?

데이터가 건물당 2천 개로 적은 편이고, 입력도 9개로 단순해서 가우시안이 잘 맞는 조건이다. 예측값마다 자신감도 같이 나온다.

Q. 왜 건물마다 따로 학습했나?

가우시안은 데이터가 많아지면 급격히 느려진다(세제곱). 2만 행을 한 번에 넣으면 시간과 메모리가 감당이 안 된다. 건물별로 나누면 2천 행이라 수 분이면 되고, 건물마다 다른 패턴도 더 잘 잡는다.

Q. 결정트리·베이지안 모델과 뭐가 다른가?

결정트리는 "기온이 28도 이상이면 → 시간이 14시 이후면 → …"처럼 조건을 나눠 가며 예측해서 계단 모양 결과가 나온다. 가우시안 프로세스는 매끄러운 곡선으로 예측하고, 넓은 의미에서 베이지안 방법의 한 종류다(사전에 "매끄러운 곡선"이라는 믿음을 두고 데이터로 갱신하는 구조). 세 모델 모두 같은 기준(마지막 7일 SMAPE)으로 비교하면 공정하다.

Q. 한계는?

느려서 데이터를 늘리기 어렵고, 훈련 때 본 적 없는 상황(갑작스런 가동 시작, 임시 휴무)은 예측할 수 없다. 이건 다른 모델도 마찬가지다.

용어 한 줄 정리
가우시안(정규)분포 종 모양 확률 분포 · **가우시안 프로세스** 곡선 전체에 대한 확률 · **회귀** 숫자 예측 · **커널** 비슷함의 규칙 · **RBF** 가까우면 비슷하다는 커널 · **길이척도** 얼마나 멀어야 다른 상황인지 · **ARD** 입력마다 길이척도 따로 · **WhiteKernel** 잡음 허용 · **하이퍼파라미터** 커널 안의 설정값, 데이터로 자동 결정 · **SMAPE** 몇 % 틀렸나의 평균 · **검증** 정답을 아는 데이터 일부를 숨겨 놓고 맞추는지 보는 것